

Guía de Actividades Práctico-Experimentales Nro. 003

1. Datos Generales

Asignatura	Metodología de la Investigación en Computación
Estudiante	Darwin José Correa Saritama
Ciclo	4 A
Unidad	1
Resultado de aprendizaje de la unidad	R1. Contrasta la investigación y sus tipos con los métodos en el área de Computación y afines.
Práctica Nro.	003
Título de la Práctica	Identificación del problema preliminar de investigación
Nombre del Docente	Luis Antonio Chamba Eras
Fecha	Martes 28 de abril de 2026
Horario	10h30 – 11h30
Lugar	EVA-Moodle / Aula
Tiempo planificado en el Sílabo	1 hora

2. Objetivo(s) de la Práctica

Identificar y documentar el problema preliminar de investigación del proyecto integrador, sus actores, contexto y variables o elementos centrales.

3. Materiales y reactivos

- Computador
- Plantilla de formulación del problema (EVA-Moodle)
- Fuentes bibliográficas recopiladas en APE 1
- Mendeley/Zotero

4. Equipos y herramientas

EVA-Moodle; guía institucional de práctica.



unl

Universidad
Nacional
de Loja

5. Procedimiento / Metodología

Desarrollo (ABI – Aprendizaje Basado en Investigación):

1. Revisar las fuentes bibliográficas recopiladas en la APE 1.
2. Identificar brechas, necesidades o problemas detectados en la literatura.
3. Redactar la descripción del problema preliminar usando la plantilla.
4. Identificar actores involucrados, contexto y variables/elementos centrales.
5. Vincular el problema con la sublínea de investigación seleccionada.
6. Subir el reporte técnico en PDF a EVA-Moodle.

6. Resultados esperados

1. Contexto general del problema

En el contexto de los Sistemas Inteligentes, específicamente en el campo del aprendizaje profundo aplicado a la visión por computador y el análisis de señales, múltiples organizaciones, centros de investigación y la industria de dispositivos inteligentes enfrentan el desafío de desarrollar sistemas de reconocimiento que operen de manera eficiente en entornos con recursos limitados, como dispositivos móviles, sistemas embebidos o sensores portables.

2. Situación actual basada en evidencia

Diversos estudios han evidenciado que la combinación de redes neuronales convolucionales y recurrentes (CNN+RNN) permite reconocer patrones de evolución en datos de conectividad, mejorando la predicción de enlaces en redes complejas [1]. Otros autores han demostrado que los algoritmos de fusión temporal de características optimizan modelos de reconocimiento de acciones en video sin añadir costo computacional adicional [2]. Asimismo, se ha reportado que las redes neuronales feedforward pueden distinguir fases de la marcha humana usando únicamente señales inerciales de sensores portables, ignorando el ruido inherente de dispositivos de bajo costo [3]. Además, se ha comprobado que las redes backpropagation combinadas con momentos invariantes de Hu logran reconocer imágenes basadas en contornos en dispositivos móviles [4]. Finalmente, se ha documentado que el algoritmo de backpropagation permite que la red aprenda una representación interna de los datos, ajustando los pesos de sus conexiones para minimizar el error de clasificación [5].

3. Brecha o vacío identificado

A pesar de los avances en precisión, existe una brecha significativa en la generalización y eficiencia de estos modelos cuando se despliegan fuera de entornos controlados. Persisten limitaciones en la capacidad de los sistemas para mantener un alto rendimiento en condiciones variables del mundo real (cambios de iluminación, terrenos irregulares, ruido en señales) sin requerir costosas arquitecturas computacionales [2][3][4]. Además, la dependencia de la elección manual de parámetros, como la ventana de tiempo en modelos híbridos CNN+RNN [1] y la calidad de la captura de datos en aplicaciones móviles [4], sumada al tamaño limitado de los conjuntos de datos de entrenamiento que puede provocar sobreajuste [4][5], impide una implementación robusta y autónoma de estos sistemas inteligentes.

4. Problema central

El problema radica en la dificultad de los sistemas de reconocimiento de datos basados en redes neuronales para integrar, durante el proceso de aprendizaje, mecanismos que les permitan extraer características invariantes y contextuales del dato (ignorando ruido, variaciones de escala o rotación [4] y dependencias temporales [1][2]), al mismo tiempo que optimizan su arquitectura para funcionar con eficiencia computacional en dispositivos con recursos limitados [2][4]; lo cual afecta directamente la precisión, adaptabilidad y aplicabilidad práctica de estos modelos inteligentes en escenarios reales.

5. Consecuencias o impacto

Esta situación genera consecuencias como una precisión de clasificación insuficiente o no confiable cuando los sistemas se enfrentan a datos del mundo real con alta variabilidad natural [3][4], una dependencia de hardware costoso y de alto consumo que limita el despliegue en tecnologías de uso masivo como drones y teléfonos móviles [2], y un sobreajuste de los modelos a los datos de entrenamiento que impide la generalización efectiva a nuevos escenarios [4][5], enlenteciendo la adopción de soluciones de IA en aplicaciones de vigilancia inteligente, diagnóstico médico asistido y robótica.

6. Actores involucrados

Los principales actores involucrados incluyen investigadores en aprendizaje profundo y visión por computador, desarrolladores de software para sistemas embebidos y aplicaciones móviles, ingenieros de datos encargados del preprocesamiento y etiquetado, y usuarios finales en sectores como la salud (pacientes con prótesis inteligentes), la seguridad (operadores de sistemas de videovigilancia) y la logística (operadores de drones).

7. Variables o elementos clave

Las variables clave asociadas al problema incluyen:

- **Variable 1:** Precisión y exactitud del reconocimiento/clasificación.
- **Variable 2:** Eficiencia computacional y costo de inferencia del modelo.
- **Variable 3:** Invarianza y calidad de las características extraídas frente a ruido, rotación y escala.
- **Variable 4:** Capacidad de generalización del modelo a diferentes datasets y condiciones no controladas.

- **Variable 5:** Dependencia de configuración manual de hiperparámetros críticos (ej. ventana de tiempo, dimensión de la muestra).

8. Delimitación del problema

El presente problema se delimita a la fase de extracción de características y clasificación de datos mediante redes neuronales artificiales (CNN, RNN, Feedforward, Backpropagation) y su desempeño en datasets estándar y experimentales, excluyendo aspectos de infraestructura de redes de comunicación, seguridad informática de los sistemas y desarrollo de hardware especializado (como la fabricación de chips neuromórficos).

9. Vinculación con la sublínea de investigación

Este problema se enmarca dentro de la sublínea de investigación **Sistemas Inteligentes**, debido a su enfoque en el estudio, análisis y optimización de la capacidad de aprendizaje automático de las redes neuronales artificiales para el reconocimiento de patrones y datos, buscando mejorar su adaptabilidad y eficiencia, un objetivo central de la inteligencia artificial aplicada.

REFERENCIAS

- [1] C. A. C. Osorio, G. A. I. Echeverry, L. F. C. Ossa, y O. H. F. Bedoya, “Computational architecture of IoT data analytics for connected home based on deep learning”, en *Proceedings of the 10th Euro-American Conference on Telematics and Information Systems*, Aveiro Portugal: ACM, nov. 2020, pp. 1–8. doi: 10.1145/3401895.3402055.
- [2] Y. Yuan, Z. Ruan, Y. Wei, y T. Jiang, “Exploration of Network Optimization Strategies Based On the TSN Model”, en *2023 6th International Conference on Algorithms Computing and Artificial Intelligence*, Sanya China: ACM, dic. 2023, pp. 151–157. doi: 10.1145/3639631.3639657.
- [3] F. Evci, Y. Saroglu, y E. I. Konukseven, “Gait Recognition and Phase Detection Using WearableIMUSensorsand Neural Network Algorithms”, en *Proceedings of the 2023 7th International Conference on Advances in Artificial Intelligence*, Istanbul Turkiye: ACM, oct. 2023, pp. 138–143. doi: 10.1145/3633598.3633620.
- [4] B. Schinzel, “IT-driven transcriptions: about gender and ethically relevant usage of speech and metaphors in computing and IT”, en *Proceedings of the 4th Conference on Gender & IT - GenderIT '18*, Heilbronn, Germany: ACM Press, 2018, pp. 3–9. doi: 10.1145/3196839.3196841.
- [5] K. Zhou, “Optimization and Application of Complex Network Structure Based on Deep Learning”, en *Proceedings of the 2025 8th International Conference on Computer Information Science and Artificial Intelligence*, Wuhan China: ACM, sep. 2025, pp. 1377–1381. doi: 10.1145/3773365.3773582.

7. Preguntas de Control

- ¿Qué diferencia existe entre un problema práctico y un problema de investigación?

Problema práctico:

Es una situación concreta que ocurre en un entorno real (organizacional, industrial, educativo) y que demanda una solución inmediata o aplicada. Se centra en resolver una dificultad específica utilizando conocimientos ya existentes. Por ejemplo, una empresa que necesita implementar un sistema de reconocimiento de imágenes para clasificar sus productos está enfrentando un problema práctico, ya que la solución se basa en tecnologías y metodologías ya disponibles.

Problema de investigación:

Es una brecha o vacío en el conocimiento científico que requiere ser investigado para generar nuevo saber. No se limita a aplicar lo ya conocido, sino que busca descubrir, explicar o comprender fenómenos no resueltos. Por

ejemplo, investigar cómo mejorar la capacidad de generalización de las redes neuronales en condiciones de iluminación variable constituye un problema de investigación, pues implica generar nuevo conocimiento sobre el comportamiento de los algoritmos de aprendizaje.

- **¿Cómo se justifica la relevancia de un problema de investigación en computación?**

Se justifica evidenciando que el problema aborda una brecha o vacío en la literatura científica. Esto se logra mediante una revisión sistemática que demuestre que el conocimiento actual es insuficiente o presenta limitaciones. Por ejemplo, los estudios analizados en tu matriz evidencian que persisten limitaciones en la generalización de modelos de redes neuronales a condiciones no controladas [1][2][3][4][5], lo que justifica la necesidad de investigar en esta dirección.

8. Evaluación

Instrumento: Rúbrica de evaluación configurada en EVA-Moodle, alineada al modelo de evaluación integral del desempeño y al PID de la Carrera.

9. Bibliografía

J. A. Yuni and C. A. Urbano, Metodología y técnicas para investigar. Buenos Aires, Argentina: Editorial Brujas, 2020.

J. W. Creswell and J. D. Creswell, Research Design: Qualitative, Quantitative, and Mixed Methods Approaches, 5th ed. Thousand Oaks, CA: SAGE, 2018.

10. Elaboración y Aprobación

Elaborado por Luis Antonio Chamba Eras <i>Docente</i>	Revisado por (Solo si aplica) <i>Técnico Docente</i>	Aprobado por Edison L. Coronel Romero <i>Director de Carrera</i>
--	---	---