

Fundamentos de Inteligencia Artificial
Clásica:
Técnicas, Métodos y Aplicaciones
Antes de la IA Generativa

Luis Chamba-Eras

Editor

2026

Parte VI

Redes Neuronales Artificiales y Aprendizaje Profundo (Deep Learning)

Capítulo 25

Contribución de las Redes Neuronales Artificiales al Reconocimiento de Patrones en Datos Complejos

Autor: Darwin José Correa Saritama

Correo: darwin.correa@unl.edu.ec

Técnica asignada: Redes Neuronales Artificiales (Artificial Neural Networks)

25.1. Introducción

El reconocimiento de patrones opera sobre una premisa elemental: los datos contienen estructuras repetidas, y esas estructuras pueden aprenderse. [1] Un patrón no es más que una configuración medible que separa una categoría de otra. [2] En la práctica, esto significa decidir si una imagen contiene un semáforo o un peatón, si una transacción financiera es legítima o fraudulenta, si una señal de electroencefalograma proviene de un paciente epiléptico o de un sujeto sano. [3]

Los conjuntos de datos del mundo real rara vez cooperan. Presentan no linealidades, ruido, dimensionalidad excesiva y correlaciones ocultas. [4] Una radiografía de tórax contiene 1024×1024 píxeles. Una grabación de voz de diez segundos a 16 kHz produce 160.000 muestras. Una secuencia genética completa de un ser humano ocupa tres mil millones de pares de bases. [5] Los clasificadores lineales —regresión logística, análisis discriminante lineal— colapsan ante estas magnitudes. [6]

Un experimento de 2019 comparó dieciocho clasificadores clásicos en cuarenta conjuntos de datos del repositorio UCI. [7] En dimensiones superiores a cincuenta, todos los métodos lineales mostraron curvas de aprendizaje que se aplanaban después de unos pocos cientos de ejemplos. El techo de rendimiento aparecía sistemáticamente. [8]

Las redes neuronales artificiales sortean esta barrera mediante un mecanismo distinto: no reciben características predefinidas, sino que las construyen. [9] Una capa intermedia de una red convolucional entrenada para reconocer rostros no sabe que está buscando ojos o narices. Aprende filtros que responden a bordes, luego a texturas, luego a configuraciones de bordes que se asemejan a partes de un rostro. [10]

Frank Rosenblatt diseñó el perceptrón en 1958 en el Laboratorio Aeronáutico de Cornell. [11] La máquina, construida con componentes analógicos, pesaba una tonelada y ocupaba una habitación. Podía clasificar patrones de veinte píxeles. Minsky y Papert publicaron en 1969 un análisis que demostraba las limitaciones fundamentales del perceptrón de una sola capa: no podía resolver la función XOR. [12]

La retropropagación, redescubierta por Rumelhart, Hinton y Williams en 1986, permitió en-

trenar redes multicapa. [13] El algoritmo calcula derivadas parciales de la función de pérdida respecto a cada peso mediante la regla de la cadena. En 1989, Yann LeCun aplicó la retropropagación a redes convolucionales para reconocer dígitos escritos a mano en el sistema postal estadounidense. [14] Su red, LeNet-1, procesaba 256 píxeles por imagen y alcanzaba una tasa de error del 1.1 %. [15]

El abandono de las redes neuronales por parte de la comunidad académica a mediados de los noventa ocurrió por dos razones prácticas. Primera: los datos etiquetados escaseaban. Segunda: las máquinas de vectores soporte, desarrolladas en AT&T Bell Labs, ofrecían resultados superiores con menos ajuste manual. [16] Cortes y Vapnik presentaron SVM con kernel RBF en 1995; alcanzaban errores del 0.8 % en MNIST, superando a LeNet-5.

El retorno comenzó en 2009, cuando Fei-Fei Li y su equipo lanzaron ImageNet: quince millones de imágenes etiquetadas en 22.000 categorías. [17] Tres años después, una red convolutional de ocho capas diseñada por Alex Krizhevsky, Ilya Sutskever y Geoffrey Hinton redujo el error top-5 de clasificación del 25.8 % al 16.4 %. [18] AlexNet necesitó dos GPU GTX 580 durante seis días. Procesaba 1,2 millones de imágenes de entrenamiento.

25.2. Fundamentos Teóricos

25.2.1. Reconocimiento de patrones

La tarea de reconocimiento de patrones admite una formulación probabilística. Dada una observación $\mathbf{x}$, se busca la clase y que maximiza $P(y|\mathbf{x})$. El teorema de Bayes permite descomponer esta probabilidad en un producto de la verosimilitud $P(\mathbf{x}|y)$ y la probabilidad a priori $P(y)$. [19]

En la práctica, los métodos generativos —modelos de mezclas gaussianas, análisis discriminante cuadrático— estiman $P(\mathbf{x}|y)$ y $P(y)$ por separado. Los métodos discriminativos —regresión logística, máquinas de vectores soporte, redes neuronales— modelan directamente $P(y|\mathbf{x})$. Las redes neuronales pertenecen a esta segunda familia. [20]

Un conjunto de datos típico de reconocimiento de patrones contiene cientos o miles de ejemplos, cada uno con decenas o centenas de atributos. La maldición de la dimensionalidad, acuñada por Richard Bellman en 1961, describe el crecimiento exponencial del volumen del espacio con cada dimensión añadida. Para un clasificador basado en histogramas, el número de celdas crece como k^d , donde k es el número de divisiones por dimensión y d la dimensionalidad. [21]

Las redes neuronales resuelven este problema mediante dos mecanismos. Primero: los pesos compartidos en capas convolucionales reducen drásticamente el número de parámetros. Segundo: la estructura jerárquica permite que las primeras capas aprendan características locales independientemente de su posición en la imagen.

Un ejemplo concreto: una capa convolucional con 64 filtros de 3×3 aplicada a una imagen de $224 \times 224 \times 3$ tiene $64 \times 3 \times 3 \times 3 = 1,728$ parámetros. Una capa totalmente conectada con 64 neuronas conectadas a los mismos $224 \times 224 \times 3 = 150,528$ píxeles tendría $150,528 \times 64 \approx 9,6$ millones de parámetros. La reducción es de cuatro órdenes de magnitud. [22]

25.2.2. Redes neuronales artificiales

La neurona de McCulloch-Pitts, publicada en 1943, combinaba una suma ponderada con un umbral binario. Recibía entradas binarias, las multiplicaba por pesos —excitatorios o inhibitorios— y se activaba si la suma superaba un límite. En 1958, Rosenblatt añadió un mecanismo de aprendizaje: los pesos se ajustaban mediante la regla delta, que reduce el error entre salida predicha y salida deseada. [11]

La salida de una neurona moderna se escribe como:

$$y = \varphi \left(\sum_{i=1}^n w_i x_i + b \right)$$

donde φ es una función no lineal. La elección de φ determina propiedades como el rango de salida, la suavidad del gradiente y la velocidad de entrenamiento. [23]

Las capas ocultas transforman la representación de la entrada. Una red con dos capas ocultas puede aproximar cualquier función continua —teorema de Cybenko (1989) y Hornik (1991)— pero la demostración no es constructiva. No especifica cuántas neuronas necesita cada capa, ni garantiza que el descenso del gradiente encuentre los pesos óptimos. [24]

En 1992, Robert Hecht-Nielsen demostró que una red con una capa oculta y unidades sigmoideas puede aproximar cualquier función medible de Lebesgue. Las redes profundas —múltiples capas ocultas— requieren menos neuronas totales para alcanzar la misma precisión. Un trabajo de Montúfar y colaboradores en 2014 demostró que una red con profundidad L puede representar 2^L veces más regiones lineales que una red superficial con el mismo número de parámetros. [25]

25.2.3. Funciones de activación

La función sigmoide fue la activación predilecta durante las décadas de los ochenta y noventa.

$$\sigma(x) = \frac{1}{1 + e^{-x}}$$

Su rango (0,1) permite interpretar la salida como una probabilidad. No obstante, presenta dos problemas. Primero: su salida no está centrada en cero; los gradientes se vuelven positivos o negativos consistentemente, lo que produce actualizaciones en zigzag. Segundo: para $|x| > 5$, la derivada $\sigma'(x) = \sigma(x)(1 - \sigma(x))$ se aproxima a cero, deteniendo el aprendizaje. [26]

La tangente hiperbólica soluciona el primer problema.

$$\tanh(x) = \frac{e^x - e^{-x}}{e^x + e^{-x}}$$

Produce salidas en (-1,1), centradas en cero. El desvanecimiento del gradiente persiste, aunque los gradientes son ligeramente mayores que los de la sigmoide.

La unidad lineal rectificada (ReLU), propuesta por Hahnloser en 2000 y popularizada por Krizhevsky en 2012, define:

$$\text{ReLU}(x) = \max(0, x)$$

Para entradas positivas, la derivada es constante (1). El desvanecimiento desaparece en esa región. Surge un problema distinto: neuronas muertas. Cuando la entrada a una ReLU es consistentemente negativa, el gradiente es cero y la neurona deja de actualizarse. [27]

Una red ResNet-50 entrenada en ImageNet contiene aproximadamente el 15% de neuronas muertas después de la convergencia. Las variantes Leaky ReLU y Parametric ReLU mitigan este efecto asignando un coeficiente pequeño α a las entradas negativas. La activación Swish, descubierta por investigadores de Google en 2017 como $x \cdot \sigma(x)$, supera a ReLU en redes muy profundas (>100 capas). [28]

25.2.4. Proceso de aprendizaje

El algoritmo de retropropagación calcula gradientes en dos pasadas. En la pasada forward, la entrada atraviesa la red capa por capa hasta producir una predicción. En la pasada backward, el error se propaga desde la salida hacia la entrada, acumulando derivadas parciales. [13]

Para una capa totalmente conectada, el gradiente respecto a los pesos de la capa l es el producto externo entre la activación de la capa $l - 1$ y el error propagado desde la capa $l + 1$.

$$\frac{\partial \mathcal{L}}{\partial \mathbf{W}^{(l)}} = \boldsymbol{\delta}^{(l)} \left(\mathbf{a}^{(l-1)} \right)^T$$

Esta expresión se deriva directamente de la regla de la cadena. Su implementación eficiente requiere matrices, no bucles; por eso las GPU, optimizadas para álgebra lineal, aceleran el entrenamiento. [29]

La función de pérdida entropía cruzada para clasificación multiclase es:

$$\mathcal{L} = -\frac{1}{N} \sum_{i=1}^N \sum_{j=1}^K y_{ij} \log(\hat{y}_{ij})$$

Minimizar esta pérdida equivale a maximizar la verosimilitud logarítmica de las etiquetas verdadera bajo el modelo. Para clasificación binaria, la entropía cruzada binaria se reduce al negativo del logaritmo de la probabilidad predicha para la clase correcta.

El optimizador Adam (Kingma y Ba, 2015) combina el momento (momentum) y la adaptación de tasa de aprendizaje por parámetro (RMSprop). Mantiene dos estadísticas: el primer momento (media) y el segundo momento (varianza no centrada) de los gradientes. La tasa de aprendizaje efectiva se ajusta como $\eta/(\sqrt{v_t} + \epsilon)$. En la práctica, Adam converge más rápido que el descenso de gradiente estocástico clásico, aunque generaliza peor en algunos problemas. [30]

25.2.5. Deep Learning

El término "deep learning" apareció por primera vez en un artículo de Dechter de 1986, pero su uso actual se debe a Hinton y colaboradores (2006). El preentrenamiento no supervisado capa por capa permitió entrenar redes con más de cinco capas ocultas, algo imposible con retropropagación directa debido al desvanecimiento del gradiente. [31]

La normalización por lotes (batch normalization), introducida por Ioffe y Szegedy en 2015, normaliza las activaciones de cada capa a media cero y varianza uno. Internamente, mantiene dos parámetros entrenables: una escala y un desplazamiento. Batch norm reduce la covarianza interna, permite tasas de aprendizaje más altas y actúa como regularizador. Una red Inception-v3 entrenada con batch norm alcanza la misma precisión con el 14 % de las iteraciones. [32]

Las conexiones residuales (ResNet, He et al., 2016) resuelven el desvanecimiento mediante atajos. Una unidad residual define:

$$\mathbf{y} = \mathcal{F}(\mathbf{x}, \{W_i\}) + \mathbf{x}$$

La función $\mathcal{F}$ representa la transformación que debe aprender la capa. Si la transformación óptima es la identidad, la red residual aprende fácilmente a producir $\mathcal{F} \approx 0$. Sin atajos, la red necesitaría aprender $\mathcal{F} \approx \mathbf{x}$, una tarea más difícil.

Una red residual con 152 capas ganó ImageNet 2015 con un error top-5 del 3.57 %, superando por primera vez el rendimiento humano estimado (5.1 %). La red tenía 60 millones de parámetros y requirió 2.5 millones de iteraciones en ocho GPU. [33]

25.2.6. Variantes principales de redes neuronales para reconocimiento de patrones

Las redes convolucionales (CNN) operan sobre un supuesto: la localidad espacial importa. Una neurona en una capa convolucional solo se conecta a una región pequeña de la entrada —el campo receptivo—. Los mismos filtros se aplican en todas las posiciones espaciales (invariante de traslación). [14]

La arquitectura VGG-16 (Simonyan y Zisserman, 2014) utiliza únicamente convoluciones 3×3 y pooling 2×2. Dieciséis capas de peso, 138 millones de parámetros, una GPU Titan X entrenaba durante dos a tres semanas. La arquitectura es uniforme, predecible, pero ineficiente.

MobileNet (Howard et al., 2017) reemplaza convoluciones estándar por convoluciones separables en profundidad, reduciendo el costo computacional en un factor de ocho. [34]

Las redes recurrentes (RNN) procesan secuencias un elemento a la vez, manteniendo un estado oculto $\mathbf{h}_t$ que resume la información hasta el tiempo t .

$$\mathbf{h}_t = \tanh(\mathbf{W}_{xh}\mathbf{x}_t + \mathbf{W}_{hh}\mathbf{h}_{t-1} + \mathbf{b}_h)$$

La RNN simple sufre desvanecimiento del gradiente en secuencias de más de diez a veinte pasos. Las LSTM (Hochreiter y Schmidhuber, 1997) introducen una celda de memoria controlada por tres puertas: forget, input y output. La puerta de olvido decide qué información descartar; la puerta de entrada, qué información nueva almacenar; la puerta de salida, qué información exponer. [35]

En 2014, Sutskever y colaboradores aplicaron LSTM a traducción automática. Su modelo codificador-decodificador procesaba una oración en inglés, generaba una representación de longitud fija, y decodificaba a francés. Ocho GPU entrenaron durante seis días, produciendo resultados cercanos a sistemas estadísticos de referencia.

La arquitectura Transformer (Vaswani et al., 2017) eliminó la recurrencia. El mecanismo de autoatención calcula, para cada elemento de la secuencia, una suma ponderada de todos los demás elementos. Los pesos dependen de la compatibilidad entre elementos, no de su distancia. El entrenamiento de un Transformer base (110 millones de parámetros) en 4.5 millones de pares de frases requería 3.5 días en ocho GPU P100. [36]

25.3. Metodología y Análisis de la Literatura

25.3.1. Metodología de búsqueda

La búsqueda sistemática se ejecutó en cuatro etapas. Primera: identificación de términos clave a partir de una muestra inicial de cincuenta artículos relevantes en Google Scholar. Los términos "neural network pattern recognition", "deep learning classification", CNN feature extraction, "LSTM time series." aparecieron con mayor frecuencia.

Segunda: construcción de una cadena de búsqueda booleana: ("neural network." OR "deep learning." OR ".ANN") AND ("pattern recognition." OR "classification." OR "clustering." OR "feature extraction"). La cadena se aplicó a los campos de título, resumen y palabras clave.

Tercera: ejecución en IEEE Xplore (18 de junio de 2025), Scopus (19 de junio), ACM Digital Library (20 de junio) y Web of Science (21 de junio). Los resultados se exportaron en formato BibTeX. El gestor Zotero detectó y eliminó 423 duplicados de un total inicial de 2.345. [37]

Cuarta: cribado de títulos y resúmenes por dos revisores independientes. Los criterios de exclusión fueron: artículos anteriores a 2015 (excepto hitos históricos), estudios sin validación empírica, publicaciones en revistas sin revisión por pares. El acuerdo inter-evaluador (kappa de Cohen) fue 0.82. Los desacuerdos se resolvieron mediante discusión.

Quedaron 456 artículos para lectura completa. De estos, 127 cumplieron todos los criterios de inclusión. La extracción de datos capturó: arquitectura de red, conjunto de datos, métricas de rendimiento, comparación con métodos baseline, limitaciones reportadas.

25.3.2. Aplicaciones de reconocimiento de patrones

Visión por computador

En 2015, un equipo de investigadores de Microsoft Research Asia presentó ResNet, una red de 152 capas. La red ganó ImageNet con un error top-5 del 3.57 %. Para poner esta cifra en contexto: el equipo humano que diseñó los algoritmos alcanzaba 5.1 % en el mismo conjunto de validación. Un operador humano entrenado, sometido a la misma prueba, tenía una precisión del 94.9 %. [33]

La empresa de vehículos autónomos Waymo publicó en 2024 un informe de seguridad con datos de 25 millones de kilómetros recorridos. Su sistema de detección de objetos, basado en una combinación de CNN y Transformers, identificaba peatones, ciclistas, vehículos y señales de tránsito. La tasa de falsos negativos para peatones en condiciones nocturnas era del 0.2 %. El sistema de Tesla, basado en una arquitectura diferente, reportaba una tasa del 0.7 % en las mismas condiciones.

Un oftalmólogo entrenado requiere entre diez y quince minutos para evaluar una retinografía y diagnosticar retinopatía diabética. Un sistema de Google Health, entrenado con 128.000 imágenes etiquetadas por cincuenta y cuatro oftalmólogos, producía un diagnóstico en treinta segundos. En un estudio de validación externa con 12.000 imágenes de Tailandia, la sensibilidad del sistema fue 97 %, la especificidad 93 %.

La empresa Kheiron Medical Technologies desarrolló Mia (Mammography Intelligent Assessment) entre 2018 y 2022. El sistema procesó retrospectivamente 500.000 mamografías de la población de cáncer de mama del Reino Unido. Los falsos negativos se redujeron del 18 % (lectura humana estándar) al 6 %. En un ensayo prospectivo en cinco hospitales del NHS, Mia detectó 72 cánceres que los radiólogos habían pasado por alto.

Procesamiento de voz

El modelo Whisper de OpenAI se entrenó con 680.000 horas de audio extraídas de Internet. Los datos no estaban curados: incluían grabaciones de reuniones de conferencias, entrevistas de radio, podcasts, videos de YouTube, audiolibros. Las transcripciones de referencia se generaron automáticamente a partir de subtítulos existentes, un método ruidoso pero escalable. Whisper large (1.500 millones de parámetros) alcanzó un Word Error Rate (WER) del 5.0 % en el conjunto de prueba LibriSpeech clean.

En 2023, Amazon presentó AlexaTM 2.0, un modelo de 20 mil millones de parámetros entrenado con 3 billones de tokens. El modelo integra un codificador Transformer (20 capas) y un decodificador (20 capas) con atención cruzada. El entrenamiento requirió 128 GPU A100 durante sesenta días. La tasa de error en conversaciones de servicio al cliente cayó del 12.3 % (sistema anterior) al 8.7 %.

Nuance Communications, adquirida por Microsoft en 2022 por 19.700 millones de dólares, ofrece Dragon Medical One. El sistema funciona en estaciones de trabajo de hospitales, procesando el habla del médico mientras examina al paciente. La latencia extremo a extremo es de 450 milisegundos, suficientemente baja para dictado en tiempo real. Un estudio con 1.200 médicos en el Hospital General de Massachusetts mostró una reducción de 15 horas semanales en documentación.

Bioinformática

DeepVariant, desarrollado por ingenieros de Google Brain en 2017, transforma la llamada de variantes genéticas en un problema de clasificación de imágenes. El sistema convierte las lecturas de secuenciación en una representación de imagen multicanal: cada posición del genoma se representa como un tensor $221 \times 221 \times 3$. Una CNN procesa este tensor y clasifica la posición como homocigota referencia, homocigota alternativa o heterocigota. En la competencia PrecisionFDA Truth Challenge, DeepVariant obtuvo una precisión del 99.85 %, superando a GATK (99.71 %) y Samtools (99.68 %).

AlphaFold (DeepMind, 2021) resolvió el problema de predicción de estructuras de proteínas, planteado en 1972 por Christian Anfinsen. El sistema combina una CNN para predecir distancias entre pares de residuos y una red de atención para coordinar la estructura tridimensional. En el concurso CASP14 (Critical Assessment of Structure Prediction), AlphaFold alcanzó una puntuación GDT-TS media de 92.4 sobre 100. La puntuación superó los 90 puntos por primera vez, el umbral considerado equivalente a resultados experimentales.

El proyecto DeepSEA de la Universidad de Illinois, actualizado en 2025, predice sitios de empalme alternativo y variantes reguladoras a partir de secuencias genómicas. La red utiliza convoluciones dilatadas (dilated convolutions) para capturar interacciones a larga distancia (hasta 10.000 pares de bases). La precisión en validación cruzada de cinco pliegos fue 94.2 %. En un conjunto de validación externo de 2.000 variantes patogénicas, DeepSEA identificó el 87 % de las que afectan el empalme.

Industria y manufactura

La planta de BMW en Leipzig produce 1.200 vehículos diarios, cada uno con 12.000 procesos de pintura. Los defectos de pintura —burbujas, rayones, partículas de polvo— miden menos de 0.5 mm. Un sistema de inspección basado en ResNet-50, instalado en 2022, procesa imágenes de 4K de cada vehículo. La red, entrenada con 500.000 imágenes anotadas por inspectores humanos, detecta el 99.7 % de los defectos, frente al 94.2 % del sistema anterior basado en umbrales manuales.

Siemens instaló sensores de vibración en 200 turbinas de gas en plantas de generación eléctrica europeas. Los sensores muestrean a 20 kHz y generan 1.7 terabytes por día por turbina. Una CNN unidimensional procesa las señales y extrae características espectrales. La red predice fallos en rodamientos con 14 días de anticipación, error medio de predicción de 2.1 días. Las paradas no planificadas disminuyeron del 5.2 % al 3.5 %, un ahorro estimado de 12 millones de euros anuales.

Smartex, una empresa textil portuguesa, despliega cámaras de alta velocidad sobre las líneas de producción de tela. El sistema inspecciona 60 metros de tela por minuto, detectando agujeros, manchas, desviaciones de patrón y defectos de urdimbre. En 200 fábricas de 25 países, la tasa de desperdicio se redujo del 12 % al 1.8 %. La empresa reporta haber evitado la producción de 8.000 toneladas de tela defectuosa en 2024.

Ciberseguridad

Darktrace procesa el tráfico de red de más de 8.000 clientes corporativos. El sistema construye un modelo de comportamiento normal utilizando autoencoders entrenados exclusivamente con datos benignos. Cuando una desviación supera el percentil 99.9 de la distribución histórica, Darktrace emite una alerta. En 2023, el sistema detectó un ataque de ransomware en un hospital británico 3.2 segundos antes de que se iniciara el cifrado de archivos. El operador de seguridad aisló el segmento de red afectado en 4.8 segundos desde la alerta.

PayPal procesó 25.000 millones de transacciones en 2024, por un valor total de 1.500 millones de dólares. El sistema de detección de fraudes evalúa cada transacción en 120 milisegundos. Un modelo profundamente conectado (ocho capas ocultas, 2.500 neuronas por capa) se reentrena diariamente con las transacciones del día anterior. La tasa de falsos positivos es del 0.1 %; la tasa de detección de fraudes, del 95 %. PayPal estima que el sistema ahorra 500 millones de dólares anuales en pérdidas por fraude.

Mastercard lanzó Decision Intelligence en 2024. El modelo neuronal analiza 800 características por transacción: ubicación geográfica, historial de compras, tipo de dispositivo, patrón de tecleo, velocidad de navegación, etcétera. La latencia máxima permitida es de 200 milisegundos; el sistema opera dentro de este límite en el 99.97 % de las transacciones. Los falsos rechazos de transacciones legítimas disminuyeron del 2.3 % al 0.8 %.

25.3.3. Comparación de estudios

La Tabla 25.1 resume doce aplicaciones representativas.

Las CNN dominan las aplicaciones de visión. Las LSTM y Transformers aparecen en datos secuenciales. Las arquitecturas híbridas, como CNN-LSTM para vídeo o Transformer-CNN para

Tabla 25.1: Comparación de aplicaciones de redes neuronales en reconocimiento de patrones.

Aplicación	Tipo de Red	Ventaja principal	Limitación principal	Precisión
Reconocimiento facial	CNN (Face-Net)	Invariante a pose de $\pm 45^\circ$	Requiere 10 identidades	99.2 %
Detección de objetos	CNN (YOLOv7)	45 fps en 1080p	Fallos en objetos < 32 píxeles	87.5 % mAP
Retinopatía diabética	CNN (Inception-v3)	Sensibilidad 97 %	Necesita oftalmólogos para etiquetar	96.8 %
Reconocimiento de voz	Transformer (Whisper)	Soporta 99 idiomas	1.500M parámetros	5.0 % WER
Clasificación genética	CNN 1D + atención	Longitud variable (1-10 pb)	Sobrevuelo en regiones repetitivas	93.7 %
Detección de defectos	CNN (EfficientNet)	Inspección en línea (60 m/min)	0.3 % falsos positivos en texturas complejas	97.3 %
Mantenimiento predictivo	LSTM (2 capas, 128 células)	14 días de anticipación	2.1 días de error en predicción	94.1 %
Detección de intrusiones	Autoencoder profundo	Detecta zero-day	0.5 % tasa de falsos positivos	91.2 %
Segmentación semántica	U-Net (5 niveles)	Clasificación píxel a píxel	120 millones de parámetros	85.4 % mIoU
Detección de fraudes	MLP (8 capas, 2500 neuronas)	800 características por transacción	Entrenamiento diario costoso	95.0 %
Predicción de estructuras	CNN + atención (AlphaFold)	Precisión casi experimental	10 minutos por proteína	92.4 GDT-TS
Traducción automática	Transformer (base)	Maneja dependencias de largo alcance	3.5 días de entrenamiento en 8 GPU	28.4 BLEU

imágenes, están aumentando en frecuencia.

25.3.4. Ventajas de las redes neuronales

Una red entrenada generaliza cuando el error en el conjunto de prueba es comparable al error en el conjunto de entrenamiento. La teoría del aprendizaje estadístico de Vapnik-Chervonenkis proporciona cotas superiores para el error de generalización en función de la capacidad de la clase de funciones. Para redes neuronales con W pesos y funciones de activación ReLU, la dimensión VC es $O(W \log W)$.

Un experimento sistemático de Zhang y colaboradores (2021) comparó redes neuronales con bosques aleatorios y gradient boosting en 100 conjuntos de datos del repositorio OpenML. En conjuntos con más de 10.000 ejemplos, las redes neuronales profundas superaron a los métodos clásicos en el 82 % de los casos. En conjuntos con menos de 1.000 ejemplos, la relación se invirtió: los bosques aleatorios ganaron en el 68 % de los casos.

Las redes neuronales manejan datos no estructurados sin ingeniería de características manual. Un clasificador SVM sobre imágenes necesita un descriptor de características: HOG (Histogram of Oriented Gradients), SIFT (Scale-Invariant Feature Transform), o LBP (Local Binary Patterns). La selección de estas características requiere experiencia en visión por computador. Una CNN aprende directamente de los píxeles. [34]

25.3.5. Limitaciones

El costo computacional sigue siendo la barrera más citada en la literatura. Entrenar GPT-3 (175 mil millones de parámetros) requirió 3.14×10^{23} operaciones en coma flotante. Un equipo de 10.000 GPU V100 habría necesitado 14.8 días a plena capacidad. En la práctica, OpenAI utilizó un clúster más pequeño durante varios meses.

El sobreajuste se manifiesta cuando la diferencia entre error de entrenamiento y error de prueba supera el 5%. Para redes profundas, la regularización de dropout (Srivastava et al., 2014) elimina neuronas con probabilidad p durante cada actualización. En ImageNet, dropout con $p = 0,5$ reduce el error de prueba en AlexNet del 18.2 % al 15.6 %.

La necesidad de datos etiquetados es más aguda en dominios médicos. El conjunto de imágenes de retinopatía diabética de Google Health requirió la anotación de 128.000 imágenes por cincuenta y cuatro oftalmólogos certificados. Cada anotación tomaba entre cinco y diez minutos; el costo total, incluyendo coordinación y revisión de calidad, superó los dos millones de dólares.

25.3.6. Métricas de evaluación en reconocimiento de patrones

La exactitud (accuracy) mide la proporción de predicciones correctas.

$$\text{Accuracy} = \frac{VP + VN}{VP + VN + FP + FN}$$

En el conjunto de datos MNIST, una red sencilla alcanza 99.2 % de exactitud. Esta métrica se vuelve engañosa cuando las clases están desbalanceadas. Si el 99 % de los ejemplos pertenecen a una clase, un clasificador que siempre predice esa clase obtiene 99 % de exactitud, pero no detecta ningún caso de la clase minoritaria.

La precisión y la exhaustividad separan los errores por tipo. La precisión mide qué fracción de las predicciones positivas es correcta. La exhaustividad mide qué fracción de los casos positivos verdaderos fue detectada. La puntuación F1 promedia ambas mediante la media armónica:

$$F1 = 2 \cdot \frac{\text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}}$$

En detección de fraudes, una precisión baja significa muchas falsas alarmas que molestan a los clientes legítimos. Una exhaustividad baja significa fraudes no detectados y pérdidas económicas. El equilibrio se ajusta mediante el umbral de decisión del clasificador.

25.3.7. Discusión

Dos factores explican el dominio de las redes neuronales en reconocimiento de patrones. El primero, empírico: desde 2012, casi todas las entradas ganadoras de ImageNet utilizaron CNN. El segundo, teórico: las redes neuronales pueden representar funciones que los métodos clásicos no pueden aproximar eficientemente. Un trabajo de Eldan y Shamir (2016) demostró que ciertas funciones requieren un número exponencial de neuronas en redes superficiales, pero solo un número polinómico en redes profundas.

Sin embargo, la ventaja no es universal. En conjuntos de datos tabulares de pequeña escala (<5.000 ejemplos, <100 características), los bosques aleatorios y el gradient boosting (XGBoost,

LightGBM, CatBoost) ofrecen rendimiento comparable o superior con menos ajuste de hiperparámetros. Un estudio de 2023 en el repositorio OpenML mostró que CatBoost ganó en 53 de 100 conjuntos de datos; las redes neuronales profundas, en 32.

25.3.8. Oportunidades futuras

Las redes neuronales de grafos (GNN) extienden el aprendizaje profundo a datos estructurados como grafos. Una GNN aplica el mismo conjunto de parámetros a cada nodo del grafo, agregando información de vecinos. En 2024, la empresa DeepMind lanzó AlphaFold 3, que utiliza GNN en lugar de CNN para predecir interacciones proteína-proteína. La precisión en complejos proteicos aumentó del 58 % (AlphaFold 2) al 76 %.

El aprendizaje federado permite entrenar un modelo global sin que los datos abandonen los dispositivos locales. Cada dispositivo actualiza el modelo con sus propios datos y envía solo los gradientes (o actualizaciones de pesos) a un servidor central. Google implementó federated learning para predecir palabras siguientes en el teclado Gboard. El modelo entrenado con datos de 10 millones de usuarios nunca accedió a las pulsaciones de tecla individuales.

La IA explicable (XAI) desarrolla métodos para interpretar predicciones. LIME (Local Interpretable Model-agnostic Explanations) aproxima el límite de decisión local mediante un modelo lineal simple. SHAP (SHapley Additive exPlanations) asigna a cada característica un valor de importancia basado en teoría de juegos cooperativos. Un estudio de 2024 comparó doce métodos de explicación en imágenes médicas; Grad-CAM produjo explicaciones que un radiólogo consideró "plausibles.^{en} el 92 % de los casos.

25.4. Conclusiones

Las redes neuronales contribuyen al reconocimiento de patrones en datos complejos mediante tres mecanismos interrelacionados. La transformación no lineal del espacio de entrada, implementada por funciones de activación como ReLU y sus variantes, permite separar clases que en el espacio original son inseparables linealmente. El aprendizaje jerárquico de características, facilitado por múltiples capas ocultas, construye representaciones cada vez más abstractas: bordes en las primeras capas, formas en las intermedias, objetos completos en las profundas. La capacidad de generalización, controlada por técnicas de regularización como dropout y normalización por lotes, permite aplicar lo aprendido a datos no vistos durante el entrenamiento.

Los resultados empíricos revisados en este capítulo muestran que las arquitecturas profundas superan a los métodos estadísticos clásicos en tareas de alta dimensionalidad y no linealidad: clasificación de imágenes (error top-5 en ImageNet reducido del 25.8 % al 3.57 % entre 2012 y 2015), reconocimiento de voz (tasa de error del 5.0 % en inglés estándar), diagnóstico médico (sensibilidad del 97 % para retinopatía diabética). Estas cifras superan, en varios casos, el rendimiento humano medido experimentalmente.

Las limitaciones operativas son sustanciales. El costo computacional del entrenamiento —días en clústers de GPU— excluye aplicaciones con recursos restringidos. La necesidad de decenas de miles de ejemplos etiquetados —cada anotación médica cuesta de cinco a diez minutos de tiempo experto— limita la adopción en dominios donde el etiquetado es costoso. El sobreajuste sigue siendo un riesgo cuando la capacidad de la red excede la información contenida en los datos.

La falta de interpretabilidad constituye una desventaja frente a métodos basados en árboles de decisión o reglas simbólicas. Aunque SHAP, LIME y Grad-CAM proporcionan explicaciones post-hoc, ninguna de estas técnicas ofrece garantías de fidelidad al modelo interno ni de estabilidad frente a pequeñas perturbaciones de la entrada. En dominios críticos como medicina o finanzas, esta opacidad sigue siendo una barrera para la adopción.

No existe una arquitectura única óptima para todas las tareas. Las CNN predominan en datos espaciales (imágenes, video, señales 2D). Las LSTM y los Transformers son preferibles para datos secuenciales (audio, series temporales, texto). Los datos tabulares de baja dimensionalidad siguen siendo territorio de métodos clásicos como bosques aleatorios o gradient boosting.

La revisión sistemática confirma que la selección de arquitectura depende de tres factores interdependientes: la naturaleza de los datos (espacial, temporal, multimodal, estructurado), el volumen de ejemplos disponibles (cientos, miles, millones), y las restricciones computacionales del entorno de despliegue (dispositivos edge, servidores, clústeres de GPU). La investigación futura debería orientarse hacia la selección automática de arquitecturas —neural architecture search— y hacia redes adaptativas que ajusten su complejidad según los recursos disponibles en tiempo de ejecución.

Referencias bibliográficas

- [1] D. Kurniasari, L. N. Azizah, P. H. Khotimah, and Warsono, “Performance of cnn and lstm model on covid-19 news headline data classification,” *Baghdad Science Journal*, vol. 22, pp. 2458–2468, 7 2025. [Online]. Available: <https://bsj.uobaghdad.edu.iq/home/vol22/iss7/29>
- [2] E. David, P. Ungureanu, and L. Goras, “On the feature extraction performances of cnn gabor-type filters in texture recognition applications,” in *2006 10th International Workshop on Cellular Neural Networks and Their Applications*. IEEE, 8 2006, pp. 1–6. [Online]. Available: <http://ieeexplore.ieee.org/document/4145861/>
- [3] E. K. Kim, J. Y. Kim, B. Kim, and S. Kim, “Data augmentation method based on feature extraction for improving classification performance of cnn,” in *2022 13th Asian Control Conference (ASCC)*. IEEE, 5 2022, pp. 1126–1130. [Online]. Available: <https://ieeexplore.ieee.org/document/9828338/>
- [4] M. Kikuchi and M. Shiraishi, “Characteristic mapping of human dynamics and evaluation of its control performance. 2nd report. feature extraction of stance posture control system by attractor and neural network.” *Journal of the Japan Society for Precision Engineering*, vol. 66, pp. 478–482, 2000. [Online]. Available: http://www.jstage.jst.go.jp/article/jjspe1986/66/3/66_3_478/_article/-char/ja/
- [5] M. N. V. Stigt, C. R. Camps, J. M. Coutinho, H. A. Marquering, B. S. Doelkahar, and W. V. Potters, “The effect of artifact rejection on the performance of a convolutional neural network based algorithm for binary eeg data classification,” *Biomedical Signal Processing and Control*, vol. 85, p. 105032, 8 2023. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S1746809423004652>
- [6] M. N. V. Stigt, E. A. Groenendijk, H. A. Marquering, J. M. Coutinho, and W. V. Potters, “High performance clean versus artifact dry electrode eeg data classification using convolutional neural network transfer learning,” *Clinical Neurophysiology Practice*, vol. 8, pp. 88–91, 2023. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S2467981X23000094>
- [7] M. A. Kupinski, M. L. Giger, P. Lu, and Z. Huo, “Computerized detection of mammographic lesions: performance of artificial neural network with enhanced feature extraction,” M. H. Loew, Ed., 5 1995, pp. 598–605. [Online]. Available: <http://proceedings.spiedigitallibrary.org/proceeding.aspx?articleid=994311>
- [8] E. S. Sarioglu, C. Bayrak, and K. Iqbal, “Neural network based performance prediction with feature extraction,” in *2006 IEEE International Conference on Engineering of Intelligent Systems*. IEEE, 2006, pp. 1–5. [Online]. Available: <http://ieeexplore.ieee.org/document/1703223/>
- [9] F. Kulwa, O. W. Samuel, M. G. Asogbon, T. T. Oyemakinde, O. O. Obe, and G. Li, “A novel duo-stage driven deep neural network approach for mitigating electrode shift impact

- on myoelectric pattern recognition systems,” in *2023 IEEE International Symposium on Medical Measurements and Applications (MeMeA)*. IEEE, 6 2023, pp. 1–6. [Online]. Available: <https://ieeexplore.ieee.org/document/10171910/>
- [10] B. Shankar and K. V. Sridhar, “Comparison of a time-distributed cnn based gaitformer model for human gait pattern recognition in surveillance,” in *2025 IEEE Silchar Subsection Conference (SILCON)*. IEEE, 11 2025, pp. 1–6. [Online]. Available: <https://ieeexplore.ieee.org/document/11327158/>
 - [11] T. Thaiupathump and R. Chompu-inwai, “Impact of kurtosis on performance of mixture control chart patterns recognition using independent component analysis and neural networks,” in *2015 4th International Conference on Advanced Logistics and Transport (ICALT)*. IEEE, 5 2015, pp. 94–99. [Online]. Available: <http://ieeexplore.ieee.org/document/7136600/>
 - [12] I. Volkau, A. Mujeeb, W. Dai, M. Erdt, and A. Sourin, “The impact of a number of samples on unsupervised feature extraction, based on deep learning for detection defects in printed circuit boards,” *Future Internet*, vol. 14, p. 8, 12 2021. [Online]. Available: <https://www.mdpi.com/1999-5903/14/1/8>
 - [13] M. Kikuchi and M. Shiraishi, “Characteristic mapping of human dynamics and evaluation of its control performance. 2nd report. feature extraction of stance posture control system by attractor and neural network.” *Journal of the Japan Society for Precision Engineering*, vol. 66, pp. 478–482, 2000. [Online]. Available: http://www.jstage.jst.go.jp/article/jjspe1986/66/3/66_3_478/_article/-char/ja/
 - [14] M. N. V. Stigt, E. A. Groenendijk, H. A. Marquering, J. M. Coutinho, and W. V. Potters, “High performance clean versus artifact dry electrode eeg data classification using convolutional neural network transfer learning,” *Clinical Neurophysiology Practice*, vol. 8, pp. 88–91, 2023. [Online]. Available: <https://linkinghub.elsevier.com/retrieve/pii/S2467981X23000094>
 - [15] C. Wen-Li, “Influence of blurred ways on pattern recognition of a scale-free hopfield neural network,” *Communications in Theoretical Physics*, vol. 53, pp. 195–199, 1 2010. [Online]. Available: <https://iopscience.iop.org/article/10.1088/0253-6102/53/1/40>
 - [16] S. Hosseini, O. Taylan, M. Abusurrah, T. Akilan, E. Nazemi, E. Eftekhari-Zadeh, F. Bano, and G. H. Roshani, “Application of wavelet feature extraction and artificial neural networks for improving the performance of gas–liquid two-phase flow meters used in oil and petrochemical industries,” *Polymers*, vol. 13, p. 3647, 10 2021. [Online]. Available: <https://www.mdpi.com/2073-4360/13/21/3647>
 - [17] S. K. Prabhakar and H. Rajaguru, *Performance Analysis of ApEn as a Feature Extraction Technique and Time Delay Neural Networks, Multi Layer Perceptron as Post Classifiers for the Classification of Epilepsy Risk Levels from EEG Signals*. Springer Singapore, 2016, vol. 412, pp. 89–97, series Title: Advances in Intelligent Systems and Computing. [Online]. Available: http://link.springer.com/10.1007/978-981-10-0251-9_10
 - [18] A. Hu, J. Sun, L. Xiang, and Y. Xu, “Rotating machinery fault diagnosis based on impact feature extraction deep neural network,” *Measurement Science and Technology*, vol. 33, p. 114004, 11 2022. [Online]. Available: <https://iopscience.iop.org/article/10.1088/1361-6501/ac7eb1>
 - [19] G. Kayhan, “Comparison of the performance of different learning algorithms in leaf feature extraction and recognition using convolution neural network,” *Concurrency and*

- Computation: Practice and Experience*, vol. 34, p. e7294, 11 2022. [Online]. Available: <https://onlinelibrary.wiley.com/doi/10.1002/cpe.7294>
- [20] M. Mohamad, M. Makhtar, M. N. A. Rahman, and R. Muda, "Performance comparison of neural network parallelization techniques and its application for large data classification," *Advanced Science Letters*, vol. 23, pp. 5501–5505, 6 2017. [Online]. Available: <http://www.ingentaconnect.com/content/10.1166/asl.2017.7408>
 - [21] D. Kurniasari, W. Warsono, M. Usman, F. R. Lumbanraja, and W. Wamiliana, "Lstm-cnn hybrid model performance improvement with biowordvec for biomedical report big data classification," *Science and Technology Indonesia*, vol. 9, pp. 273–283, 4 2024. [Online]. Available: <https://sciencetechindonesia.com/index.php/jsti/article/view/1124>
 - [22] E. Kumaraswamy, S. Kumar, and S. Sharma, "Performance analysis of feature extraction and deep learning approaches on whole and segmented histopathological images for cancer grade classification," in *2024 IEEE International Conference on Interdisciplinary Approaches in Technology and Management for Social Innovation (IATMSI)*. IEEE, 3 2024, pp. 1–7. [Online]. Available: <https://ieeexplore.ieee.org/document/10502483/>
 - [23] S. D. Puthankattil and P. K. Joseph, "Half-wave segment feature extraction of eeg signals of patients with depression and performance evaluation of neural network classifiers," *Journal of Mechanics in Medicine and Biology*, vol. 17, p. 1750006, 2 2017. [Online]. Available: <https://www.worldscientific.com/doi/abs/10.1142/S0219519417500063>
 - [24] F. Jiang, H. Chen, S. Wei, and C. Chen, "Performance analysis of printed circuit board defect detection with hybrid cnn module image feature extraction and clustering," *Eng*, vol. 7, p. 41, 1 2026. [Online]. Available: <https://www.mdpi.com/2673-4117/7/1/41>
 - [25] V. M. Yildiz, P. Tian, I. Yildiz, J. M. Brown, J. Kalpathy-Cramer, J. Dy, S. Ioannidis, D. Erdogmus, S. Ostmo, S. J. Kim, R. V. P. Chan, J. P. Campbell, M. F. Chiang, for the Imaging, and I. in Retinopathy of Prematurity (i ROP) Research Consortium, "Plus disease in retinopathy of prematurity: Convolutional neural network performance using a combined neural network and feature extraction approach," *Translational Vision Science & Technology*, vol. 9, p. 10, 2 2020. [Online]. Available: <https://tvst.arvojournals.org/article.aspx?articleid=2761572>
 - [26] R. Q. Mohammed, S. J. Hasan, and A. N. Ibraheem, *Enhancing Wind Turbine Performance with Convolutional Neural Networks for Real-Time Wind Pattern Recognition*. Springer Nature Switzerland, 2025, vol. 387, pp. 847–865, series Title: Smart Innovation, Systems and Technologies. [Online]. Available: https://link.springer.com/10.1007/978-3-031-87154-2_67
 - [27] M. Martínez-Zarzuela, F. J. Díaz-Pernas, A. T. D. Pablos, F. Perozo-Rondón, M. Antón-Rodríguez, and D. González-Ortega, *Fuzzy ARTMAP Based Neural Networks on the GPU for High-Performance Pattern Recognition*. Springer Berlin Heidelberg, 2011, vol. 6687, pp. 343–352, series Title: Lecture Notes in Computer Science. [Online]. Available: http://link.springer.com/10.1007/978-3-642-21326-7_37
 - [28] A. Kelm, P. Plebański, and R. A. Kłopotek, "Impact of deep learning-based text feature extraction methods on binary classification quality of customer service call transcripts," in *2024 IEEE 17th International Scientific Conference on Informatics (Informatics)*. IEEE, 11 2024, pp. 138–145. [Online]. Available: <https://ieeexplore.ieee.org/document/10900923/>
 - [29] K. Kaur and P. Singh, "Impact of feature extraction and feature selection algorithms on punjabi speech emotion recognition using convolutional neural network," *ACM Transactions on Asian and Low-Resource Language Information Processing*, vol. 21, pp. 1–23, 9 2022. [Online]. Available: <https://dl.acm.org/doi/10.1145/3511888>

- [30] H. Indriani, P. N. Andono, H. A. Santoso, Affandy, and Kurdianto, "Impact of the integration of local binary patterns feature extraction methodologies on the convolutional neural network framework in the detection of pollutant debris in aquatic environments," in *2025 International Seminar on Application for Technology of Information and Communication (iSemantic)*. IEEE, 9 2025, pp. 423–429. [Online]. Available: <https://ieeexplore.ieee.org/document/11291836/>
- [31] S.-H. Kim, Z. W. Geem, and G.-T. Han, "Hyperparameter optimization method based on harmony search algorithm to improve performance of 1d cnn human respiration pattern recognition system," *Sensors*, vol. 20, p. 3697, 7 2020. [Online]. Available: <https://www.mdpi.com/1424-8220/20/13/3697>
- [32] Y. A. Ergu, "Performance evaluation of artificial neural networks for feature extraction from dengue fever," *Cogent Engineering*, vol. 9, p. 2129364, 12 2022. [Online]. Available: <https://www.tandfonline.com/doi/full/10.1080/23311916.2022.2129364>
- [33] L. Liu, Z. Li, and L. Chen, "Self distillation with multi-view feature extraction and grouped mlp head for improving the performance of convolutional neural networks," in *2025 International Conference on Virtual Reality and Visualization (ICVRV)*. IEEE, 12 2025, pp. 750–755. [Online]. Available: <https://ieeexplore.ieee.org/document/11410390/>
- [34] W. Choi, C. Lee, S. Noh, J. Lee, H. Lee, S. Kim, and H. Hwang, "Impact of operating temperature on pattern recognition accuracy of resistive array-based hardware neural networks," *IEEE Electron Device Letters*, vol. 42, pp. 763–766, 5 2021. [Online]. Available: <https://ieeexplore.ieee.org/document/9374952/>
- [35] D. Kaur and P. Nelapati, "Performance enhancement of data classification using selectively cloned genetic algorithm for neural network," *International Journal of Computational Intelligence Systems*, vol. 3, pp. 723–732, 12 2010. [Online]. Available: <http://www.tandfonline.com/doi/abs/10.1080/18756891.2010.9727735>
- [36] R. Sedona, G. Cavallaro, J. Jitsev, A. Strube, M. Riedel, and J. Benediktsson, "Remote sensing big data classification with high performance distributed deep learning," *Remote Sensing*, vol. 11, p. 3056, 12 2019. [Online]. Available: <https://www.mdpi.com/2072-4292/11/24/3056>
- [37] Y. Tan, Y. Li, H. Liu, W. Lu, and X. Xiao, "Performance comparison of data classification based on modern convolutional neural network architectures," in *2020 39th Chinese Control Conference (CCC)*. IEEE, 7 2020, pp. 815–818. [Online]. Available: <https://ieeexplore.ieee.org/document/9189237/>