



Universidad
Nacional
de Loja

Universidad Nacional de Loja

Facultad de la Energía, las Industrias y los Recursos Naturales
No Renovables

Carrera de Computación

¿Cómo contribuyen las redes neuronales al
reconocimiento de datos?

How do neural networks contribute to data
recognition?

Metodología de la Investigación en
Computación.

AUTOR:

Darwin Correa

TUTOR:

Prof. Luis Chamba-Eras

Loja, Ecuador

2026

Declaración de uso de IA Generativa

Yo, **Darwin Correa**, en calidad de autor, declaro de manera transparente y responsable el uso de herramientas de Inteligencia Artificial Generativa (DeepSeek) durante el desarrollo del presente trabajo, en conformidad con los principios de integridad académica, ética investigativa y buenas prácticas en el uso de tecnologías emergentes.

1. Alcance del uso de IA generativa

El uso de herramientas de IAG se ha limitado a funciones de apoyo, sin sustituir el juicio crítico ni la autoría intelectual del autor. En particular, se han utilizado para:

- Mejora de redacción y estilo académico.
- Generación de ideas preliminares.
- Apoyo en la estructuración del documento.
- Asistencia en traducción técnica.

2. Clasificación del uso según GAIDeT

De acuerdo con la taxonomía GAIDeT, el uso de IA generativa en este trabajo se clasifica en:

- **Nivel 1 – Asistencia Lingüística:** Corrección gramatical y mejora de claridad.
- **Nivel 2 – Apoyo en Ideación:** Generación de ideas y esquemas conceptuales.
- **Nivel 3 – Asistencia Técnica:** Apoyo en generación de código y explicaciones técnicas.

No se ha utilizado IA generativa para la generación autónoma de resultados ni para sustituir el análisis crítico del autor.

3. Validación y responsabilidad

Todo contenido asistido por IA ha sido revisado, validado y adaptado por el autor, quien asume la responsabilidad total sobre la calidad, veracidad y originalidad del trabajo.

4. Herramientas utilizadas

Se emplearon modelos de lenguaje (LLMs) y herramientas de asistencia técnica para redacción, estructuración y apoyo conceptual.

5. Consideraciones éticas

El uso de IA se realizó respetando principios de honestidad académica, normativas institucionales de la Universidad Nacional de Loja y buenas prácticas internacionales.

6. Declaración final

Declaro que el uso de IA generativa ha sido ético, transparente y complementario, sin comprometer la autoría ni la integridad académica del presente trabajo.

Loja, Ecuador, [Fecha]

[Nombre del Estudiante]

Autor

Índice General

Declaración de uso de IA Generativa	1
Índice de Algoritmos	6
Índice de Códigos	7
Índice de Ecuaciones	8
Índice de Anexos	9
Introducción a los Antecedentes	9
Trabajos Previos y Evolución del Campo	9
Hallazgos Clave Identificados en la Literatura	11
Brecha de Investigación	11
Referencias	13

Índice de Tablas

Índice de Figuras

Índice de Algoritmos

Índice de Códigos

Índice de Ecuaciones

Índice de Anexos

- **Anexo 1.** (Título del Anexo 1) p. x
- **Anexo 2.** (Título del Anexo 2) p. y

1. Introducción a los Antecedentes

El reconocimiento de datos se ha consolidado como un área fundamental dentro de la inteligencia artificial, abarcando desde la clasificación de imágenes hasta el procesamiento de señales biomédicas y el análisis de texto. En las últimas décadas, las redes neuronales profundas han demostrado un rendimiento sobresaliente en estas tareas; sin embargo, su naturaleza de "caja negra" limita la interpretabilidad y confiabilidad en dominios críticos como la salud, las finanzas y la industria. En respuesta a esta limitación, han surgido los sistemas híbridos neuro-simbólicos, que buscan integrar la capacidad de aprendizaje de las redes neuronales con el razonamiento simbólico y la transparencia de los sistemas basados en reglas. La presente sección revisa los trabajos previos más relevantes, identifica los hallazgos clave en la literatura y establece la brecha que justifica esta investigación.

2. Trabajos Previos y Evolución del Campo

2.1 Redes Neuronales para Reconocimiento de Datos

Los primeros estudios que compararon redes neuronales artificiales (ANN) con métodos estadísticos clásicos sentaron las bases del campo. Obaidat y Abu-Saymeh [?] demostraron que una ANN con retropropagación reducía el error de clasificación de transductores ultrasónicos al 6 %, superando ampliamente al perceptrón (23 %) y al método de Bayes (54 %). Este hallazgo evidenció la superioridad de los enfoques conexionistas para tareas de reconocimiento de patrones.

Con la llegada del aprendizaje profundo, las arquitecturas convolucionales (CNN) revolucionaron el reconocimiento de imágenes. Tan et al. [?] compararon seis arquitecturas CNN modernas (ZFNet, VGG16, ResNet18, ResNet101, GoogLeNet y DenseNet) en conjuntos de datos no publicados, demostrando que todas superan a los métodos

convencionales. Por su parte, Shaheen et al. [?] realizaron un estudio crítico que matiza esta superioridad, mostrando que un perceptrón multicapa (MLP) con parámetros adecuados puede igualar o incluso superar a una CNN en ciertos escenarios, especialmente cuando el conjunto de datos es pequeño o las características son linealmente separables.

En el dominio del reconocimiento de series temporales y señales, Kim et al. [?] propusieron un método de optimización de hiperparámetros basado en el algoritmo de búsqueda de armonía para CNN 1D, logrando una precisión del 96.7% en el reconocimiento de patrones respiratorios. Asimismo, Hu et al. [?] desarrollaron una red neuronal profunda con núcleos wavelet de Laplace (IFE-DN) para el diagnóstico de fallos en maquinaria rotativa, logrando alta precisión y capacidad de generalización.

2.2 Emergencia de los Sistemas Híbridos Neuro-Simbólicos

La falta de interpretabilidad de las redes neuronales profundas ha impulsado la investigación en sistemas híbridos que combinan aprendizaje neuronal con razonamiento simbólico. Wang et al. [?] presentan una taxonomía sistemática del cómputo neuro-simbólico, identificando tres paradigmas principales: (1) redes neuronales con extracción de reglas simbólicas post-hoc, (2) arquitecturas que integran capas simbólicas diferenciables y (3) sistemas basados en grafos de conocimiento y embeddings.

En esta línea, Xin et al. [?] propusieron el marco NSMECRL para la orquestación inteligente de dispositivos electrónicos de consumo, integrando autoencoders variacionales (VAE) con grafos bayesianos y embeddings geométricos. Este sistema logró una reducción del 42.7% en complejidad computacional, demostrando que la hibridación no solo mejora la interpretabilidad sino también la eficiencia.

Un avance significativo en la integración de representaciones simbólicas en arquitecturas neuronales modernas es el trabajo de Hersche et al. [?], quienes introdujeron un modelo neuro-vector-simbólico para resolver matrices progresivas de Raven. Utilizando representaciones distribuidas de alta dimensionalidad como lenguaje común entre redes neuronales y sistemas simbólicos, este enfoque logró un rendimiento comparable al humano en tareas de razonamiento analógico.

2.3 Aplicaciones en Dominios Críticos

Los sistemas híbridos han encontrado aplicaciones prometedoras en dominios donde la interpretabilidad es crítica. En el área de salud, Yang et al. [?] desarrollaron NeSySwarm-IDS, un sistema end-to-end que integra una CNN ligera con un razonador de lógica difusa de Lukasiewicz para la detección de intrusiones en enjambres de drones, reduciendo la brecha semántica entre el tráfico de red y las restricciones de seguridad. Por otro lado, Kim et al. [?] propusieron un marco neuro-simbólico para el

análisis de salud en tiempo real desde dispositivos portátiles, fusionando conocimiento médico externo con patrones fisiológicos multimodales mediante redes neuronales lógicas (LNN).

En el ámbito industrial y logístico, Zhao et al. [?] presentaron LogiFusion, un sistema experto semántico-cinético que emplea aprendizaje contrastivo cruzado para alinear datos heterogéneos en un espacio latente compartido, facilitando el razonamiento de agentes basados en LLM. Hoge et al. [?] introdujeron LogicLSTM, un modelo de memoria a largo plazo guiado por una red de tensores lógicos (LTN) para el diagnóstico de fallos en cajas de engranajes, optimizando la extracción de características relevantes mediante restricciones lógicas.

3. Hallazgos Clave Identificados en la Literatura

A partir de la revisión de la literatura, se identifican los siguientes hallazgos clave:

1. **Superioridad de las redes neuronales sobre métodos estadísticos:** Las ANN reducen significativamente el error de clasificación en comparación con métodos tradicionales (Bayes, K-means, perceptrón) [?].
2. **La extracción automática de características no siempre es superior:** En ciertos escenarios (datos pequeños o linealmente separables), un MLP con características manuales puede igualar o superar a una CNN [?].
3. **Las arquitecturas híbridas mejoran la interpretabilidad sin sacrificar precisión:** La integración de capas simbólicas o lógica difusa permite explicar las decisiones manteniendo un alto rendimiento [?, ?].
4. **El espacio de características de entrada influye significativamente en el rendimiento:** La selección adecuada de parámetros de entrada (ej. TPI, pendiente, textura) determina la calidad de la extracción de características en CNN [?].
5. **La optimización de hiperparámetros es crucial para el rendimiento:** Métodos como búsqueda de armonía pueden reducir drásticamente el número de iteraciones necesarias (de 2,000,000 a 3,652) manteniendo o mejorando la precisión [?].

4. Brecha de Investigación

A pesar de los avances significativos en sistemas híbridos neuro-simbólicos, se identifican las siguientes brechas que justifican la presente investigación:

1. **Falta de marcos unificados para reconocimiento multimodal:** La mayoría de los sistemas híbridos están diseñados para dominios específicos (salud, logística, finanzas) y no generalizan bien a tareas multimodales que combinan visión, lenguaje y series temporales. Shylaja y Sheshikala [?] señalan que las arquitecturas híbridas cross-domain requieren mayores desarrollos.
2. **Limitada evaluación en entornos ruidosos y datos no balanceados:** Los estudios existentes suelen evaluarse en conjuntos de datos limpios y balanceados. Se requiere investigar la robustez de los sistemas híbridos en condiciones realistas con ruido, datos faltantes y clases desbalanceadas.
3. **Alta complejidad computacional de las arquitecturas híbridas:** Aunque Xin et al. [?] reportan reducción del 42.7% en complejidad, la mayoría de los sistemas híbridos siguen siendo computacionalmente costosos, lo que limita su despliegue en dispositivos edge y aplicaciones en tiempo real.
4. **Inexistencia de un benchmark estandarizado:** No existe un conjunto de datos de referencia ni métricas unificadas para comparar sistemas neuro-simbólicos, lo que dificulta la replicabilidad y el avance del campo.

Por lo tanto, esta investigación se propone diseñar y evaluar una arquitectura híbrida neuro-simbólica para el reconocimiento de datos multimodales que combine eficiencia computacional, interpretabilidad y robustez ante condiciones ruidosas, contribuyendo así a cerrar las brechas identificadas.

Referencias

1. M. S. Obaidat and D. S. Abu-Saymeh, "Performance comparison of neural networks and pattern recognition techniques for classifying ultrasonic transducers,in *Applied Computing: Technological Challenges of the 1990's*, pp. 1234-1242, 1992. DOI: 10.1145/130069.130153.
2. Y. Tan, Y. Li, H. Liu, W. Lu, and X. Xiao, "Performance Comparison of Data Classification based on Modern Convolutional Neural Network Architectures,in *Chinese Control Conference (CCC)*, 2020, pp. 815-818. DOI: 10.23919/CCC50068.2020.9189237
3. F. Shaheen, B. Verma, and M. Asafuddoula, "Impact of Automatic Feature Extraction in Deep Learning Architecture,in *2016 International Conference on Digital Image Computing: Techniques and Applications (DICTA)*, 2016, pp. 1-8. DOI: 10.1109/DICTA.2016.7797053.
4. S.-H. Kim, Z. W. Geem, and G.-T. Han, "Hyperparameter optimization method based on harmony search algorithm to improve performance of 1D CNN human respiration pattern recognition system,"*Sensors*, vol. 20, no. 13, art. no. 3697, 2020. DOI: 10.3390/s20133697.
5. A. Hu, J. Sun, L. Xiang, and Y. Xu, "Rotating machinery fault diagnosis based on impact feature extraction deep neural network,"*Measurement Science and Technology*, vol. 33, no. 11, art. no. 114004, 2022. DOI: 10.1088/1361-6501/ac7eb1.
6. W. Wang, Y. Yang, and F. Wu, "Towards Data-And Knowledge-Driven AI: A Survey on Neuro-Symbolic Computing,"*IEEE Transactions on Pattern Analysis and Machine Intelligence*, vol. 47, no. 2, pp. 878-899, Feb. 2025. DOI: 10.1109/T-PAMI.2024.3483273.
7. Z. Xin, K. M. K. Raghunath, and C. R. Bhat, "Smart Decision Orchestration for Consumer Electronics Management Using Dynamic Neuro-Symbolic AI Fusion,"*IEEE Transactions on Consumer Electronics*, vol. 71, no. 4, pp. 12047-12055, Apr. 2025. DOI: 10.1109/TCE.2025.3610191.
8. M. Hersche, M. Zeqiri, L. Benini, A. Sebastian, and A. Rahimi, ".^ neuro-vector-symbolic architecture for solving Raven's progressive matrices,"*Nature Machine Intelligence*, vol. 5, pp. 363-375, Apr. 2023. DOI: 10.1038/s42256-023-00630-8.
9. G. Yang, L. Ni, T. Xia, Q. Shi, and J. Li, "NeSySwarm-IDS: End-to-End Differentiable Neuro-Symbolic Logic for Privacy-Preserving Intrusion Detection in UAV Swarms,"*Applied Sciences*, vol. 16, no. 7, art. no. 3204, Jul. 2026. DOI: 10.3390/app16073204.

10. S.-Y. Kim, D. Saravanan, and G. Anbazhagan, ".Edge Neuro-Symbolic AI Framework for Privacy-Preserving Real-Time Health Analytics in Consumer Wearable Devices," *IEEE Transactions on Consumer Electronics*, vol. 72, no. 1, pp. 2290-2299, Jan. 2026. DOI: 10.1109/TCE.2025.3646489.
11. X. Zhao, J. He, Y. Yang, J. Yu, and S. Hong, "LogiFusion: a semantic-kinetic-dynamic expert system for closed-loop intralogistics decision intelligence," *Expert Systems with Applications*, vol. 308, art. no. 131147, 2026. DOI: 10.1016/j.eswa.2026.131147.
12. E. Hogeia, D. M. Onchiş, R. Yan, and Z. Zhou, "LogicLSTM: Logically-driven long short-term memory model for fault diagnosis in gearboxes," *Journal of Manufacturing Systems*, vol. 77, pp. 892-902, 2024. DOI: 10.1016/j.jmsy.2024.10.003.
13. M. Shylaja and M. Sheshikala, "Hybrid Deep Learning Architectures for Cross-Domain Pattern Recognition: Bridging Advances in Machine Learning and High-Performance Computing,in *2025 17th IEEE International Conference on Computational Intelligence and Communication Networks (CICN)*, 2025, pp. 495-500. DOI: 10.1109/CICN67655.2025.11368016.
14. A. E. Maxwell, W. E. Odom, C. M. Shobe, D. H. Doctor, M. S. Bester, and T. Ore, ".Exploring the Influence of Input Feature Space on CNN-Based Geomorphic Feature Extraction From Digital Terrain Data," *Earth and Space Science*, vol. 10, no. 5, art. no. e2023EA002845, 2023. DOI: 10.1029/2023EA002845.